

# 个性化推荐系统技术进展

刘君良 李晓光

辽宁大学信息学院 沈阳 110036

(1403432327@qq.com)



**摘要** 推荐系统通过获取用户的历史行为数据,如网页的浏览数据、购买记录、社交网络信息、用户地理位置等,来推断用户偏好。随着计算机技术的发展,推荐系统所采用的推荐技术由早期的基于用户-项的数据矩阵分解技术为主,逐渐向与数据挖掘、机器学习、人工智能等技术相融合的方向发展,从而深度挖掘用户行为的潜在偏好,以构建更加精准的用户偏好模型。推荐过程也从静态预测发展到实时推荐,通过与用户实时交互来使推荐结果更加丰富。文中重点回顾了推荐系统在不同时期所采用的关键技术,主要包括基于内容过滤的推荐技术、基于协同过滤的推荐技术、基于深度学习的推荐技术、基于强化学习的推荐技术和基于异构网络的推荐技术等。最后对比和分析了关键技术的优缺点,并对推荐系统的未来发展进行展望。

**关键词:** 推荐算法;矩阵分解;神经网络;强化学习;异构信息网络

**中图法分类号** TP311.5

## Techniques for Recommendation System: A Survey

LIU Jun-liang and LI Xiao-guang

College of information, Liaoning University, Shenyang 110036, China

**Abstract** The recommendation system obtains users' historical behavior data to predict their preferences, such as web browsing data, purchase records, social network information, users' geographical location and so on. With the development of computer technology, the recommendation technology is mainly based on user-item data matrix decomposition technology in the early stage. Afterwards, it is gradually integrated with data mining, machine learning, artificial intelligence and other technologies, so as to deeply mine the potential preferences of user behavior and build a more accurate user preference model. The recommendation process also moves from static prediction to real-time recommendation, enriching the recommendation results through real-time interaction with users. This paper mainly reviews the key technologies adopted by the recommendation system in different periods, including content-based filtering technology, collaborative filtering technology, recommendation technology based on deep learning, recommendation technology based on reinforcement learning, recommendation technology based on heterogeneous information network. Finally, this paper analyzes the advantages and disadvantages of key technologies, and then looks forward to the future development of the recommendation system.

**Keywords** Recommendation algorithms, Matrix factorization, Neural network, Reinforcement learning, Heterogeneous information network

### 1 引言

随着互联网、物联网和云计算技术的迅猛发展,现代社会是一个信息化、数字化的社会,数据充斥着整个世界。面对大量的数据,用户对信息的利用率反而降低了,即产生了信息超载(Information overload)问题。推荐系统是有效解决信息超载难题的关键技术之一,其根据用户需求为用户推荐其感兴趣的信息。经过二十余年的发展,推荐系统现已被大量应用

于电子商务、搜索引擎、智慧教育等领域。

随着概率统计、机器学习、人工智能、数据挖掘技术的不断发展,推荐系统所采用的技术也从传统的矩阵分解、概率矩阵分解等推荐技术,向基于现代人工智能技术的推荐技术演进。传统的推荐系统主要可以分为两类:基于内容过滤(Content Filtering)的推荐系统与基于协同过滤(Collaborative Filtering)的推荐系统等。基于内容过滤的推荐系统主要是通过项特征与用户特征的匹配或相关程度来筛选或排序推荐项。

到稿日期:2020-02-25 返修日期:2020-05-08 本文已加入开放科学计划(OSID),请扫描上方二维码获取补充信息。

基金项目:国家自然科学基金联合基金项目(U1811261);辽宁省教育厅服务地方项目(LFW201705)

This work was supported by the National Natural Science Foundation of China (U1811261) and Liaoning Education Department Service Local Projects(LFW201705).

通信作者:李晓光(xgli@lnu.edu.cn)

基于内容过滤的推荐系统根据推荐项类别采用不同的特征抽取与描述技术,如文本类的项采用了大量自然语言理解、信息检索等领域的相关技术,图像与视频类的项采用了数字图像处理领域的相关技术。基于协同过滤的推荐系统则是利用相近兴趣或具有共同经验的群体喜好来推荐个体感兴趣的信息。基于协同过滤的推荐系统主要采用矩阵分解或概率矩阵分解技术,其基本思想是构造用户-项目的评分矩阵,通过分解评分矩阵来获取未知项评分。传统的推荐技术在许多实际推荐系统中取得了良好的效果,但也存在许多需要解决的问题,如冷启动问题和数据稀疏问题。近年来,随着深度神经网络、强化学习、图神经网络等技术的发展,基于机器学习技术的推荐系统得到了越来越多的关注。特别是大数据技术的出现,使得推荐系统应用场景所积累的历史数据也有所增大。系统与系统之间也不再相互独立,系统可以获得大量相关的关联数据,使得机器学习技术获得了大量的可用数据。利用大数据、机器学习技术可以捕捉到复杂的用户偏好信息。利用多系统的异构数据,推荐系统可以有效地解决传统推荐技术中存在的冷启动和数据稀疏等问题,并且增加了推荐项目的多样性和准确性。

本文在介绍传统推荐技术的基础上,重点阐述了当前基于机器学习技术的推荐技术的进展。本文第 2 节简述了传统推荐技术;第 3 节讨论了以深度学习为主的推荐技术;第 4 节介绍了基于强化学习与其他技术的推荐模型;第 5 节给出了相关技术的分析比较;最后,回顾了整个推荐技术的发展,并展望推荐系统的未来发展方向。

2 传统推荐技术

推荐系统在最早期主要应用于电商类应用。系统通常被设计为根据用户的购买历史或项目评级向用户推荐项目。早期的推荐系统主要分为基于内容过滤的推荐系统、基于协同过滤的推荐系统和混合推荐系统 3 类。

2.1 基于内容过滤的推荐技术

基于内容的推荐技术主要是利用推荐项的特征相似度进行推荐。该类方法通常提取项的特征来表示物品,利用用户历史评价数据(如喜欢/不喜欢的项特征数据)来学习该用户的偏好特征。最后通过比较用户的偏好特征与潜在的物品特征,来为用户推荐相关项。目前,常见的计算相似度的方法有余弦距离、相关性系数、KL 距离等,以及项的特征描述技术,如 TFIDF、n-gram 等。

基于内容的推荐技术的应用范围广泛,其可以处理文本类数据,例如 Yahya 等<sup>[1]</sup>提出了 Web 挖掘的网页推荐系统,Manjula 等<sup>[2]</sup>通过计算文本内容的相似度来推荐期刊,Sun 等<sup>[3]</sup>提出了基于内容的个性化知识服务推荐算法 CROA 等。推荐项也可以是非文本类数据,例如 Yanir 等<sup>[4]</sup>从文本的写作风格中推测情感的强烈级别,Amit 等<sup>[5]</sup>提出了基于图像的内容推荐模型等。

基于内容的推荐技术的优点是易于实现、具有良好的解释性、不存在冷启动等问题。但是,该方法在提取特征以及度量高维特征数据的相似性方面存在一定挑战。例如,对于文

本、图像类的非结构化数据等,其特征描述依然制约着该方法的应用效果;高维数据的相似性度量的稀疏性也极大地影响了推荐效果。基于内容的过滤还会忽略项目的多样性和流行度偏见,导致推荐的物品可能是重复的。

2.2 基于协同过滤的推荐技术

协同过滤使用用户-项(User-Item)二维评价矩阵来寻找相似的用户。该类技术侧重于从数据中寻找某些隐含的模式,并将用户和项的表达映射到隐含模式上。协同过滤主要分为基于邻域的协同过滤和基于模型的协同过滤两大类。

2.2.1 基于邻域的协同过滤技术

基于邻域的协同过滤主要通过已有评分来直接预测新的评分,其中基于邻域的协同过滤分为基于用户的协同过滤与基于项的协同过滤。

基于用户的协同过滤方法应用时间较早,例如 David 等<sup>[6]</sup>首次提出基于用户的协同过滤并将其用于垃圾邮件过滤;Paul 等<sup>[7]</sup>于 1994 年利用该技术构建新闻过滤系统 GroupLens。基于项的协同过滤方法适用于拥有大量数据基础的系统,例如 Badrul 等<sup>[8]</sup>提出了基于项的协同过滤方法,Greg 等<sup>[9]</sup>于 2003 年将系统应用 Amazon 商品系统。基于项的协同过滤技术都曾广泛应用在 Netflix,Hulu 以及 YouTube 上。

基于用户的协同过滤方法可以发现用户的潜在偏好,但是存在冷启动问题且运算量较大。基于项的协同过滤方法基本不存在冷启动问题,而且在推荐时具有实时性,但是仅仅在项的数量远少于用户数量的情况下,该方法才适用。这两种方法在大规模环境下的推荐效率较低,只适用于小规模场景。因此,基于邻域的协同过滤算法常见于早期的推荐系统中,或用于数据量较小的情况。

2.2.2 基于模型的协同过滤技术

基于模型的协同过滤通常对用户-项的关系建立某种关联模型,通过最优化模型参数来获得项的最佳预测。典型的方法有基于矩阵因子分解的协同过滤方法和基于贝叶斯概率语言生成模型的协同过滤方法。基于矩阵因子分解的协同过滤方法主要采用矩阵分解技术将用户-项空间映射到低秩空间,通过降低维度来更好地捕捉用户和项目的偏好特征表达。该类方法采用的矩阵分解技术主要有 SVD<sup>[10]</sup>,NMF<sup>[11]</sup>,WMF<sup>[12]</sup>等。

概率矩阵分解<sup>[13]</sup>(Probabilistic Matrix Factorization)由于其丰富的语义表达能力,是处理基于模型的协同过滤问题的重要方法。首先,概率矩阵分解将矩阵中的元素 $R_{ij}$ 看作用户潜在偏好向量 $U_i$ 和项潜在属性向量 $V_j$ 的内积,并且服从均值为 $U_i^T V_j$ 、方差为 $\sigma$ 的一个正态分布。那么,评分矩阵 $R$ 的条件概率如下:

$$p(R|U,V,\sigma^2) \sim \prod_{i=1}^N \prod_{j=1}^M N(U_i^T V_j, \sigma^2)^{I_{ij}} \tag{1}$$

然后,假设 $U$ 和 $V$ 相互独立,那么根据贝叶斯公式可得出潜变量 $U,V$ 的后验分布:

$$p(U,V|R,\sigma^2,\sigma_U^2,\sigma_V^2) = \frac{p(U,V,R,\sigma^2,\sigma_U^2,\sigma_V^2)}{p(R,\sigma^2,\sigma_U^2,\sigma_V^2)} \\ \sim p(R|U,V,\sigma^2)p(U|\sigma_U^2)p(V|\sigma_V^2)$$

$$= p(\mathbf{R}|\mathbf{U}, \mathbf{V}, \sigma^2) \times p(\mathbf{U}|\sigma_U^2) \times p(\mathbf{V}|\sigma_V^2) \quad (2)$$

最终,将  $\mathbf{R}, \mathbf{U}, \mathbf{V}$  的联合分布对数化,并为了限制评分的范围,将高斯函数的均值加入 logistic 函数  $g(x)$ 。最后能量的函数为:

$$E(\mathbf{U}, \mathbf{V}) = \frac{1}{2} \sum_{ij} I_{ij} (\mathbf{R}_{ij} - g(\mathbf{U}_i^T \mathbf{V}_j))^2 + \frac{\lambda_U}{2} \sum_i \mathbf{U}_i^T \mathbf{U}_i + \frac{\lambda_V}{2} \sum_i \mathbf{V}_i^T \mathbf{V}_i \quad (3)$$

然后,使用梯度下降法求解  $\mathbf{U}_i$  和  $\mathbf{V}_j$  中的每一个元素。

传统的矩阵分解方法在矩阵数据过多或过于稀疏时效果不佳,而概率矩阵分解缓解了这些问题。但是,概率矩阵分解技术也有需要改进的地方:1)可以用其他算法优化求解过程。例如最小二乘法、随机梯度下降法、最大期望法和马尔可夫链蒙特卡罗算法等;2)没有考虑到评分过程中用户的个人偏好,可以加入偏置,例如贝叶斯概率矩阵分解等;3)PMF 算法假设所有用户都是独立的并且分布均匀,但这种假设在现实生活中是不存在的。因此,在评分矩阵之外添加辅助信息是一种解决方法。例如, Ma 等<sup>[14]</sup>提出添加了社交邻域信息的概率矩阵推荐算法,通过使用用户的社交网络信息来处理数据稀疏性问题; Wu 等<sup>[15]</sup>提出添加了物品自身含义的协同过滤方法,使用知识图谱将语义数据嵌入一个低维的语义空间中。这些手段都提升了推荐结果的准确性。此外,社交因素、浏览记录、发表过的图片和评论都可以作为辅助数据来丰富矩阵。如今大部分基于模型的协同过滤算法都是从 PMF 算法改进而来的。

基于贝叶斯概率语言生成模型的协同过滤是将潜在 Dirichlet 分配<sup>[16]</sup>和 PMF 算法相结合,是一类对文字隐含主题进行建模的模型。Chen 等<sup>[17]</sup>提出了 TRCF 模型,以解决非常用评分项的数据稀疏问题等。Wang 等<sup>[18]</sup>提出了一种模型对内容信息进行充分的表示学习,以解决辅助信息稀疏时的问题。这些模型都是在 CTR(Collaborative Topic Regression)模型的基础之上修改的。CTR 模型由于出众的性能被广泛应用于其他语言生成模型。

Wang 等<sup>[19]</sup>提出了协作主题回归模型(CTR)来推荐论文和科学文章,协作主题回归模型假设项目潜在因素取决于文本的潜在主题分布,并在建模评级时添加潜在变量以抵消项目的主题分布。该算法可以同时发现根据相似用户来推荐的旧文章和反映用户偏好的新文章。最后,该算法还具有很好的解释性。

协作主题回归模型将反馈矩阵和项目内容无缝集成到同一模型中,解决了矩阵分解技术的难题。通过结合 Matrix Factorization 技术(MF)和潜在 Dirichlet 分配,CTR 实现了比基于 MF 的协同过滤更好的预测性能,并且其能够为用户建立标签,具有更好的可解释结果。此外,利用项目内容信息,CTR 可以预测对于矩阵外项目的反馈。

Chen 等<sup>[20]</sup>提出了 CTR-SMF 模型,其将基于社会因素的矩阵分解和 CTR 模型进行结合以解决推荐问题。已知一个社交网络图  $G$ 、顶点集  $V$  和矩阵  $\mathbf{Q}$ ,  $\mathbf{Q}$  为社交网络图  $G$  的社交网络矩阵。 $\mathbf{V}_i$  和  $\mathbf{V}_k$  是一对顶点,  $\mathbf{q}_{ik}$  表示用户  $i$  与  $k$  的关系,  $\mathbf{d}_{ik}$

表示两者关系的强度。 $\mathbf{U}_i$  和  $\mathbf{S}_k$  分别表示用户特定的特征向量和社会因素的特征向量。观察到的社交网络关系的条件分布可以显示为:

$$p(\mathbf{Q}|\mathbf{U}, \mathbf{S}, \sigma_Q^2) = \prod_{i=1}^m \prod_{k=1}^m N(q_{ij} | g(\mathbf{U}_i^T \mathbf{S}_k), \sigma_Q^2)^{I_{ij}^Q} \quad (4)$$

通过贝叶斯定理进行推导,结合 LDA 和 SMF 得出:

$$p(\mathbf{U}, \mathbf{V}, \mathbf{S}|\mathbf{Q}, \mathbf{R}, \sigma_Q^2, \sigma_R^2, \sigma_U^2, \sigma_V^2, \sigma_S^2) \propto p(\mathbf{R}|\mathbf{U}, \mathbf{V}, \sigma_R^2) p(\mathbf{Q}|\mathbf{U}, \mathbf{V}, \sigma_Q^2) \times p(\mathbf{U}|\sigma_U^2) p(\mathbf{V}|\sigma_V^2) p(\mathbf{S}|\sigma_S^2) \quad (5)$$

学习完最佳参数后求解该模型。

该模型的主要优点是可以自动推断有用的潜在主题和社交信息,并且该模型的表现始终优于 CTR 模型。因为该模型使用社交网络信息来更好地模拟用户潜在空间,即更好地模拟来自类似朋友的用户偏好。但是,该模型建模所需的时间复杂度高于 CTR 模型。

协同过滤技术有很多优点。第一,对于物品或用户不需要建立复杂的模型,其可应用在很多领域并能在大部分场景中产生较好的推荐结果。第二,协同过滤所推荐的物品不局限于类似物品,可以推荐内容上不相似的新颖物品。协同过滤技术也存在很多缺点。第一,由于协同过滤技术是基于历史数据来预测新的项,因此新用户会存在冷启动问题。PMF 和 CTR 算法都是基于矩阵的算法,只是预测矩阵中“空白”位置数据的方法不同。新的用户、物品在矩阵中没有评分数据,因此无法对用户或者项进行推荐。第二,协同过滤技术如原始的矩阵分解技术等,普遍存在数据稀疏性问题,但 PMF 算法及其改进算法有效地缓解了这个问题的。第三,协同过滤推荐的效果依赖于用户历史偏好数据的准确性,这一点是以 PMF 技术为主的协作过滤推荐模型都存在的问题,只能在求解过程中加入一些约束条件来缓解。第四,协同过滤技术存在不够灵活和难于提供解释性等缺点。

### 2.3 混合推荐

混合推荐(Hybrid Recommendation)通过组合不同推荐系统来弥补各自推荐技术的弱点,从而达到更好的推荐效果。其通常是将基于内容的推荐技术和协同过滤技术融合到一个模型中。例如, Aysun 等<sup>[21]</sup>提出了一种基于协同过滤和基于内容过滤的混合推荐模型进行天气推荐; Vipul 等<sup>[22]</sup>提出了 WebBot 模型,将协作过滤和基于内容的过滤技术相混合来推荐餐馆。

在现实应用中,混合算法被大量应用于大型成熟网站、各种手机软件等。混合推荐方法具有很多优势:1)通过集成学习来融合多种模型,以实现更高的准确性;2)混合模型没有冷启动问题;3)能利用附加的信息,如推荐中可能会获取到除评分以外的用户信息(如上下文信息、评论信息等),可以使推荐结果更加丰富。但是混合推荐方法需要通过大量的调试工作才能使模型平衡,需要耗费大量的时间和人力。

## 3 基于深度学习的推荐技术

随着深度学习的兴起,神经网络已经应用于各种推荐问题。例如, Chen 等<sup>[23]</sup>通过神经网络捕捉用户动态偏好的改变来实时推荐项目; Niu 等<sup>[24]</sup>提出了 NPR 模型用于提高社



交网络中图像推荐的质量等。基于深度学习的推荐系统通过学习数据的潜在特征来捕捉用户深层次的偏好,与传统的协作过滤相比可处理各类复杂的用户数据。常用于推荐系统中的深度学习模型有递归神经网络、卷积神经网络、生成式对抗网络等。

3.1 基于递归神经网络的推荐技术

基于递归神经网络(Recursive Neural Network)的推荐技术可以通过建模用户的历史序列行为来预测用户的下一个动作。递归神经网络及其变体长短期记忆网络(Long Short Term Memory networks, LSTM)和门控循环单元(Gated Recurrent Unit, GRU)也已被广泛应用于顺序推荐中。例如, Balazs 等<sup>[25]</sup>利用 GRU 提出基于会话的推荐模型; Yu 等<sup>[26]</sup>提出了基于 RNN 的动态递归篮模型,在学习用户的动态表示的同时捕获篮子之间的全局顺序特性等。

Zhou 等<sup>[27]</sup>提出 RIB 框架,其通过捕捉微观行为和顺序建模用户信息来预测用户将要购买的物品。该框架考虑到用户浏览商品时的微观行为,将浏览的产品、用户的活动以及停留时间作为模型的输入序列。该框架由 5 层组成:输入层的输入是用户  $u$  的  $n$  个微观行为序列,定义为序列  $Su = \{x_1, x_2, \dots, x_n\}$ ,其中每个  $x_i$  是一个元组;在嵌入层中将序列  $x_i$  变成一个低维稠密向量 $e_i$ ,以解决数据稀疏和数据高维的问题;在 RNN 层捕捉序列的微观行为;在注意力层为每个隐藏单元分配适当的重量,有助于在输出层获得更平衡的输出。

RIB 框架有两个创新之处,首先是模拟了用户宏观动作中的顺序信息,其次是有效地捕捉了各种微观行为。但在捕获模拟微观行为时有 3 个缺点:1)用户是一系列元组,因此用户表示或输入数据非常稀疏且高维;2)序列中的微观行为是相关的,无法对微观行为的序列信息进行建模;3)捕捉微观行为的难点在于处理用户的停留时间,停留时间的长短并不能完全反馈出用户的喜好。

Duc-T 等<sup>[28]</sup>使用 LSTM 处理顺序信息并提出 Beacon 模型。该模型将用户的历史信息划分为组,即一个组为一个“篮子”,篮子往往包含支持特定需求的相关项目组。模型通过收集历史信息来预测下一篮子中的所有项目,主要由 3 个部分组成:相关敏感篮子编码器、篮子序列编码器和相关敏感预测器。首先,将篮子序列和相关矩阵作为输入,序列  $S$  表示篮子的时间顺序列表, $C$  表示相关矩阵。然后,篮子编码器捕获篮内物品相关性并将篮子编码器转换成二进制矢量。最后,篮子表示的序列被进一步馈送到序列编码器中,以捕获篮间的顺序关联。序列编码器的输出与相关矩阵一起被预测器用于产生下一个篮子。

基于递归神经网络的推荐技术常被用于购物网站,递归神经网络因其特性可以对时序信息进行建模。而在电子商务系统中,用户的浏览历史和用户动作序列的顺序会影响其购买行为,因此推荐系统常使用 RNN 获取用户的浏览历史和顺序。RIB 模型和 Beacon 模型都利用了物品的序列关系进行推荐,但两个模型的推荐思路不同。RIB 模型通过序列中前几个物品的关系来预测序列中的下一个项目。而 Beacon 模型是将用户采用的一系列“篮子”作为输入,目标是预测可

能属于下一篮子的一组物品,即实际上不处理项目序列,而是处理篮子序列。例如,用户购买了一篮子物品,RIB 模型会推荐这个篮子中的下一个物品,而 Beacon 模型会根据当前篮子中的物品去推测下一次购物时用户购买的一篮子物品是什么。基于递归神经网络的推荐技术与基于相似度和基于矩阵分解的方法相比有许多优点:1)基于递归神经网络的推荐技术可以避免数据稀疏问题,并且加入了“时间”这个影响因素;2)基于递归神经网络的推荐技术对推荐和短期预测的效果较好,但是递归神经网络在训练时会出现梯度膨胀或梯度消失问题,而且问题会随着网络层数的增加变得越来越明显,出现这种问题的原因是网络层数量太多,网络权值更新不稳定,可以使用不同的激活函数来缓解此问题。

3.2 基于卷积神经网络的推荐技术

卷积神经网络(Convolutional Neural Network)是一类包含卷积计算且具有深度结构的前馈神经网络。基于卷积神经网络的推荐系统主要是从数据中提取潜在因素和特征,如提取图像、音频等非结构化数据的特征。例如,Wang 等<sup>[29]</sup>提出了一种自动的 CNN 图像分类推荐系统;Zheng 等<sup>[30]</sup>利用两个并行的 CNN 从评论中提取语义信息,以获取用户和商品的潜在特征。

在卷积神经网络及其变体方面,感知卷积网络(A-CNN)和 VGGNet16 也被大量应用于各种模型。Ma 等<sup>[31]</sup>提出 CoA-CAMN 模型,即交叉注意记忆模型,通过 VGG-Net16 提取出图片的内容并与推文结合,以捕获用户偏好。该模型分为 3 个部分,第 1 部分使用预先训练的 VGG-Net16 来提取模型中图像的表示,包括给定推文和帖子历史的图像;第 2 部分使用推文编码器来表示推文,在 LSTM 上使用共同注意机制,来提取文本信息的重要部分和推文的视觉信息;第 3 部分编码了用户的历史兴趣和候选用户的历史兴趣,借助新颖的交叉注意机制来捕捉高质量的后期历史兴趣信息。

传统的基于 CNN 的推荐模型只是简单地结合了文本特征向量和图像特征,但是正确的实体或有意义的内容通常仅与图像或文本的一小部分内容相关,因此使用矢量表示图像或文本会产生不正确的预测。CoA-CAMN 结合了一种注意机制来处理推文的文本信息和视觉信息,此模型可以关注推文的视觉和文本信息的重要部分,这几乎可以获取多模式推文的完整含义,可以将图像内容视为辅助信息来充分利用视觉信息。

Tang 等<sup>[32]</sup>提出了 Caser 的卷积序列嵌入模型,该方法提供了一个统一的网络结构,结合卷积神经网络 CNN 来学习顺序特征,并使用潜在因子模型 LFM 来学习用户特定特征。Caser 模型由 3 个部分组成:嵌入查找层、卷积层和完全连接层。嵌入查找层通过提取用户序列中的多个连续项,并将其嵌入到神经网络中来捕获潜在空间中的序列特征。卷积层将顺序模式视为此局部特征的“图片”。连接层连接两个卷积层的输出,并将它们反馈到一个完全连接的神经网络层,使用卷积过滤器将最近的行为建模为时间、潜在维度与学习顺序模式之间的“图片”。Caser 模型既可以进行跨平台的知识转移,又可以捕获用户-用户之间和用户-项目之间的相关性,是一

种较新的 Top-N 推荐解决方案。

Li 等<sup>[33]</sup>提出了一种基于神经序列的推荐模型——RNS 模型,其利用用户评论进行预测。RNS 模型使用 A-CNN 来提取用户评论的潜在因素、用户的内在偏好以及个人的时间偏好。首先利用评论分别形成用户文档和项目文档,将每个单词嵌入到序列中;然后采用分层关注机制捕获用户序列模式,利用类似于彩色图像的多通道卷积操作进行特征提取;最后,该模型在获得该编码的时间顺序信息之后,将用户的长期偏好和短期时间偏好相结合,以获得混合表示并提出更准确的下一项推荐。

使用深度学习技术来增强顺序推荐是一类常见的模型,此类模型可以在不同的时间步骤对历史项目赋予不同的权重,以达到推荐的目的。RNS 模型的创新之处在于进行顺序推荐的同时还考虑了用户的语义信息。该模型通过考虑一般偏好和物品之间的顺序关系来动态地近似用户当前的偏好,并且利用了用户评论信息。该模型是在顺序推荐领域中首个利用文本评论来获取语义的模型。

基于卷积神经网络的推荐技术常用于社交媒体或含有图片信息的网站中。CNN 可以处理高清、内容丰富的图片信息,因此使用该技术的推荐系统可以挖掘用户大量的背景信息,例如图片信息等,以进行更全面的推荐。除了提取非结构性数据等丰富数据来源,基于卷积神经网络的推荐技术会考虑数据的顺序模式。顺序模式在推荐中是一个很重要的因素,序列中最近的交互物品对下一个物品的推荐有重要的影响。Caser 模型和 RNS 模型都考虑了这一点。Caser 模型的主要思想是在时间和潜在空间上将最近一系列物品嵌入到一个图像中,然后用卷积过滤器学习顺序模式。RNS 模型也同样利用了用户行为中的行为顺序,但是并没有学习顺序模式,而是将用户历史购买物品的序列和用户的固有偏好融合进行推荐。但是,基于卷积神经网络的推荐系统也存在一些缺点:1)在建模时需要调参并且需要大量样本,因为当网络层数太多时,采用反向传播算法时修改参数会使靠近输入层的参数改动较慢,而采用梯度下降算法时存在训练结果收敛于局部最小值的问题;2)RNN 在推荐系统中提取的数据特征是抽象的,其物理含义不能得到很好的解释。

3.3 基于生成式对抗网络的推荐技术

生成式对抗网络(Generative Adversarial Networks)是一种深度学习模型,该网络包括两个模块:基于生成式的网络学习模型以及基于判别式的网络学习模型。基于生成式对抗网络的推荐系统通过两个模型的互相博弈来学习用户的历史数据,排列出前  $k$  个用户感兴趣的项;基于生成式的模型算法有 Deepwalk, Node2vec, Metapath2vec 等;基于判别式的模型算法有 DNCR, SDNE, Ppne 等。

Wang 等<sup>[34]</sup>提出了 IRGAN 模型,用于信息检索。该模型借鉴了 GAN 中生成器和判别器相互对抗的思想,将生成检索模型和判别检索模型统一到一个框架中,并利用强化学习来训练生成器。IRGAN 模型首先选取相关的文档构成数据对并将其送入生成器中,然后根据生成的数据来训练判别器并最小化判别能力,从而完成一次对抗。该模型通过多次

对抗来不断训练数据。

IRGAN 模型有以下两个优点:1)在判别式模型中引入文本外的特征,例如行为特征等,丰富了数据来源;2)在生成式模型中,根据生成式模型的学习进度来控制生成样本的多样性程度。因此,该模型的推荐效果良好。IRGAN 模型也存在缺点,首先,生成式检索模型认为检索和文档之间存在潜在的生成过程,其缺点在于很难利用其他相关的信息,如点击文档的次数、文档和文档之间的内在联系等;其次,判别式检索模型同时将检索和文档作为特征,预测它们之间的相关性,其缺点在于缺乏获取有用特征的方法。

Wu 等<sup>[35]</sup>使用 GAN 构建了一个新的推荐模型——PD-GAN,以增加推荐结果的多样性,它由生成网络(生成器)和判别网络(鉴别器)相互竞争组成。如果在系统中有多个用户、多个项目和多个项目类别,则该模型从每个用户的历史数据中分别抽取不同类别下的项目。PD-GAN 的目的是生成前  $k$  个既多样化又相互相关的推荐项。模型的生成器首先通过矩阵分解评估所有项目的相关性,然后将相关性分数与预先学习的 DPP 模型相结合。PD-GAN 的鉴别器试图区分生成器生成的前  $k$  项,通过对抗性学习,生成器能够生成一组不同却相关的项目。PD-GAN 的生成器采用了 DPP 模型来学习不同项目的一般共现情况,并结合用户的个性化偏好生成既多样化又相关的推荐。

与 IRGAN 模型相比,PD-GAN 模型的推荐结果更具多样性。PD-GAN 模型同时考虑了两个方面的偏好,个人对个体项目的偏好,以及个人对一组项目的喜好,在保持推荐结果相关性的同时又保证了推荐的多样性。PD-GAN 模型在帮助网站服务商探索用户的潜在利益方面发挥了重要作用。基于生成式对抗网络的推荐技术是一种新兴的技术,由于生成式对抗网络具有运行时间短、可以产生更好的样本、运算便捷等优点,提高了推荐结果的精准性和多样性。并且,推荐结果的多样化可以在扩大用户视野和帮助用户在线服务提供商探索用户的潜在利益方面发挥重要作用,但是其同样存在不收敛、推荐结果过于自由化等缺点。目前,生成式对抗网络还只是初步应用在推荐系统中,随着对 GAN 的深度研究,会有越来越多的相关模型出现。

4 其他推荐技术

4.1 基于强化学习的推荐技术

强化学习(Reinforcement Learning)是智能体(agent)在与外界的交互过程中不断学习并成为最优策略的过程。基于强化学习的推荐系统可进行动态的推荐,即通过实时交互来调整推荐策略。例如 Wang 等<sup>[36]</sup>提出了基于回归神经网络的监督强化学习模型 SRL-RNN,来进行个性化药物推荐;Zhao 等<sup>[37]</sup>提出了一种基于多智能体强化学习的深度链方法,能够捕获不同场景之间的顺序相关性,从而进行综合推荐。

Zhao 等<sup>[38]</sup>提出了 DEERS 模型并利用强化学习找出学习的最优策略。该模型认为用户的浏览状态不仅应包含用户单击或订购的正项,还应包含负(跳过)项。正状态  $s^+$  表示用

户之前点击或购买过的物品序列,负状态 $s^-$ 表示之前略过的物品序列。其根据用户点击或跳过的行将推荐物品 $a$ 为加入到两个物品序列中,并使用GRU处理两个序列中的物品,最后通过DQN模型计算出 $Q$ 值。

传统的推荐模型将推荐过程视为静态过程,并只推荐当下收益最大的项。而该模型将推荐过程视为用户和agent之间的顺序交互,并通过最大化用户的预期长期累积奖励来得出最佳推荐策略。除此之外,该模型还从用户的行动中捕获正/负反馈,来调整推荐的策略。该模型将点击动作视为正反馈,将跳过行为视为负反馈,以帮助模型更好地理解用户偏好。但是,模型中用户跳过项目的原因有多种,并不能确定用户的真实喜好,因此可以加入停留时间等其他因素来完善该框架。

Zou等<sup>[39]</sup>提出了FeedRec模型,通过追踪马尔可夫过程来跟踪用户的兴趣转变,进行精准的推荐。该模型由两个网络组成,即 $Q$ 网络和 $S$ 网络, $Q$ 网络负责建模复杂的用户行为, $S$ 网络用来模拟环境,协助 $Q$ 网络并消除策略中收敛的不稳定性问题。生成过程如下:首先在 $Q$ 网络中获取用户的长期历史行为信息,并将其顺序地输入原始行为嵌入层中;然后经过LSTM处理送入 $Q$ 值层进行学习;最后将数据库中的数据输入到 $S$ 网络中,让其学习真正客户的反应,从而生成用户数据。 $S$ 网络解决了 $Q$ 学习中出现的不稳定和分歧的问题。

FeedRec模型解决了如何收集长期用户行为特征的问题,传统的推荐系统需要大量的环境交互来模拟长期行为并有效地训练agent。而该模型通过LSTM建模一个用户行为链,例如点击、跳过、浏览、排序、停留等动作,并可以模拟用户的长期行为来进行精准推荐,而不是仅考虑当下行为之后做出推荐。

对于以强化学习为主要技术的推荐模型,如何随着用户行为和时间的动态变化来捕获最符合用户的偏好是最主要的挑战,本节中的两个模型,即DEERS模型和FeedRec模型,分别从不同角度来解决该问题。DEERS模型通过用户的正负反馈来捕获用户的实时偏好,而FeedRec模型则直接为用户建模,记录用户的长期喜好,为用户推荐物品。从长期收益的角度来看,FeedRec模型的推荐效果更好。基于强化学习的推荐系统与传统的推荐系统相比有很多优点。传统的推荐系统将推荐的过程视为静态的并根据已有的条件来进行推荐,只能推荐针对当下利益最大的项。而基于强化学习的推荐系统能够在交互过程中不断更新策略,可以进行多轮推荐直到系统收敛到最佳策略为止,因此可以生成最符合用户偏好的动态推荐。并且,用户的行为特征反馈很好地解决了传统推荐模型中数据稀疏的问题等。但是基于强化学习的推荐系统在真实环境上的表现并不出色,并且大部分模型都可以看作是监督学习,因此强化学习在推荐系统上的应用还有很多问题需要解决。

4.2 基于异构网络的推荐技术

异构信息网络(Heterogeneous Information Network)可以通过融合不同类型的数据,将用户不同类型的偏好集成到同一框架中,因此是解决推荐系统数据稀疏的另一种重要技

术。最近,基于异构信息网络的推荐模型由于对复杂信息建模具有优势而备受关注。例如Shi等<sup>[40]</sup>提出一种挖掘多个用户之间潜在结构的特征嵌入推荐模型HERec;Yu等<sup>[41]</sup>提出了通过HIN获取用户隐式偏好进行推荐的推荐系统;Wang等<sup>[42]</sup>提出了基于HIN的音乐推荐系统(HIN-MRS);Wu等<sup>[43]</sup>根据风险投资的特点提出了VC-Recom模型,以帮助投资企业找到合适的创业项目等。

Hu等<sup>[44]</sup>基于上下文的元路径来建立一个三通道模型MCRec。该模型用 $\langle user, meta-path, item \rangle$ 三元组来将元路径明确地合并到交互模型中,并通过MLP多层感知机来对项目进行打分,最后实现Top-N推荐。这种方法能够从基于元路径的上下文中有效地挖掘和提取有用信息,以提高推荐性能。给定用户和项目之间的交互,我们可以得到用户、项目和元路径连接的嵌入。通过这种方式,基于元路径上下文的表征将更灵活,以适应不同的交互场景,从而为推荐结果提供良好的可解释性,这使得基于HIN的模型在一定程度上实现了性能提升。该模型的新颖之处在于明确地表征基于元路径的上下文,以改进交互的建模。此外,使用共同注意机制改进的交互嵌入算法,可使不同用户对原路径有不同的偏好。

Wang等<sup>[45]</sup>提出了基于HIN的单一嵌入模型HueRec用于推荐。该模型首先将用户和项目嵌入到一个统一的潜在空间中,然后设计了一个端到端的训练模型来提取信息和推荐,以避免丢失信息,最后用注意机制来权衡用户对元路径的偏好。该模型认为用户或项目在不同元路径下存在一些共同特征,因此模型使用元路径之间的相互关系来缓解一个元路径上的数据稀疏性和噪声问题。大多数基于HIN的推荐模型总是对元路径下的用户和项目进行单独建模,这可能导致信息提取错误并且丢失信息。而HueRec模型利用元路径之间的相互关系来缓解单个元路径上的数据稀疏性和噪声问题,并且提高个性化推荐的效果。

MCRec模型使用元路径对用户和项进行建模。但是,该模型总是在每个元路径下对用户和项目进行单独建模,并没有考虑到元路径之间的关系,这可能导致信息提取错误。而HueRec模型考虑到每个用户或项在不同元路径下存在某些共同特征,并使用来自所有元路径的数据来学习单一用户和项目的表示,因此HueRec模型的推荐效果优于MCRec模型。基于异构信息网络的推荐系统与传统的推荐系统相比具有许多优点,因为其加入了更多的用户背景信息,并以元路径的概念,使得基于异构信息网络的推荐系统在推荐效果、可解释性、多样性上的表现都很好。但是,基于HIN的方法也有很多缺点:1)没有在推荐方法中学习路径或元路径的显式表示;2)很少考虑交互中元路径和涉及的用户-项对之间的相互影响。

4.3 基于其他框架的推荐技术

Yang等<sup>[46]</sup>提出一个基于Python的开放模块化框架OpenRec,以改善推荐系统的可扩展性和适应性问题。该模型由3个部分抽象组成:模块、推荐器以及一组效用函数。模块为每类算法组件提供标准输入/输出接口,推荐器提供了从模块构建端到端系统的机制。该模型将每种推荐算法视为一



个模块,并通过一组接口组合在一起。

OpenRec 混合模型相比传统的推荐算法具有良好的适应性和扩展性。OpenRec 模型的适应性体现在没有场景的限制,因此可以广泛用于各种推荐技术和场景,例如交互式、会话式和群组推荐。该模型的可扩展性体现在可以在现有模块的基础上开发新算法,因此该模型可以适用于大部分场景。与传统的推荐模型不同,该模型更像是一组标准,各种推荐算法可以融合到一起,为推荐算法提供了一种新的思路。

Yi 等<sup>[47]</sup>提出了一个多指针共同注意网络模型 MPCN。该模型从用户对项的评论中提取特征,首先将用户和项的文字信息转化为序列,然后分别从每个用户和项目的输入序列中选择最具信息性的序列,并将其压缩为一个单独嵌入项,最后使用多个指针,使最具信息性的评论能够用于预测并能实现更深层次的单词级交互。该模型通过提取文本中的词来匹配需要推荐的物品。

文献[47]主要通过提取评论中的关键信息来获取用户的偏好,这种思路并不新颖,并且随着深度学习的兴起,各种利用评论推荐的创新模型逐渐被推出。但是,与传统模型不同,该模型从评论中提取关键信息的技术有所提升。例如,该模型对每个类别的评论都独立建模,并且每类评论的权重不同。其利用了一种新颖的基于指针的学习方案,这不仅减少了噪音,还实现了用户和项目之间的深层词级交互。最重要的是,用户和项目评论并没有以常见的压缩矢量来表示,而是以单词级别进行交互,这大大提升了从评论中提取有用信息的概率。

Zhang 等<sup>[48]</sup>提出了基于哈希码的深度学习框架 DDL。该模型是一种基于散列的混合推荐框架,由协作过滤和深度置信网络组成。通过联合优化基于 DBN 的目标和基于 CF 的目标来获得有效的哈希码,并计算用户和项目的哈希码之间的汉明距离来估计用户的偏好,从而进行建模。

该框架的创新点在于使用了散列技术,该技术是将用户和项编码为汉明空间中的二进制代码,通过计算汉明距离来取代计算用户的偏好,可较好地解决推荐系统效率低下的问题。该技术有两个优点:1)使用在汉明空间内查找最近的邻居项技术来代替传统的按照预测偏好排序的技术,减小了时间复杂度;2)汉明空间存储二进制代码时只需要一位,节省了空间复杂度。

随着用户个性化越来越被重视,推荐系统逐渐被大家研究,因此除了主流的推荐技术外,还有许多其他技术被移植到推荐领域中,如文献[47]与文献[48]将指针技术和哈希码应用在了推荐系统中。并且,随着研究人员对推荐系统不同角度的理解,会有越来越多的技术应用在推荐系统中,这些技术的加入会推动推荐系统的发展。

个性化推荐系统最早是为电子商务网站而制定的,根据用户的喜好向用户推荐其感兴趣的物品。随着推荐系统的发展,大量不同类型的推荐系统被应用在多个领域内,其中,运用相似度技术、概率矩阵分解技术、神经网络、强化学习和异构网络这 5 种技术的推荐系统的推荐效果最具有代表性。对推荐系统不同时期的这 5 种技术进行对比总结,如表 1 所列。

表 1 推荐技术的比较  
Table 1 Comparison of recommended techniques

技术	稀疏性	冷启动	可解释性	推荐效果
相似度	存在	存在	易于解释	只能推荐用户历史使用过的相关物品
概率因子分解	存在	存在	从概率的角度解释矩阵分解	无法处理较大的数据集,但在小数据集上表现较好
神经网络	部分存在	存在	存在解释问题	对用户和项提取特征时效果较好,推荐结果丰富,无扩展性
强化学习	不存在	存在	易于解释	可以动态地推荐项目,需平衡未来最大收益与即时推荐项的关系
异构网络	不存在	可较好处理	存在解释	将不同类型的历史数据融合在一起,推荐结果丰富

**结束语** 推荐系统旨在帮助用户发现其可能感兴趣的项,已成为现代网站和各类软件必备的功能之一。目前,推荐系统获得了广泛的关注,并且有许多模型和算法被提出。虽然目前的研究已取得了一定的成果,但仍然存在一些需要探索的问题,以下 3 点可能会成为主流的研究方向。

(1)知识跨域迁移与异构网络。知识跨域迁移与异构网络的结合可以在不同领域学习用户的历史数据。此类推荐系统通过分析大量不同种类的历史数据来推荐新的项给用户。与传统推荐系统相比,其推荐的效率更高,推荐的结果更具多样性。但是,对于大量数据的处理,迁移与提取用户偏好将是该方向的几个难点。

(2)基于强化学习的实时推荐。推荐过程是一个动态过程,基于强化学习的实时推荐系统可以在获取用户的实时反馈后立即调整推荐目标,以提高推荐效果。对于此类推荐系统,即时捕获用户兴趣的改变,调整即将推荐项目的优先级是

需要处理的难点。

(3)新的基于神经网络模型的推荐系统。每个基于神经网络的推荐系统有单独的应用背景,因此单一模型不可能适用于所有背景,需要根据不同的用处建立基于神经网络的模型,如商品推荐、影片推荐、视频推荐、场所推荐等。因此,基于神经网络模型的推荐系统会被广泛应用。

参 考 文 献

[1] YAHYA A M, MD N S, NORWATI M, et al. Improved web page recommender system based on web usage mining [C]// The 3rd International Conference on Computing and Informatics (ICOCI). 2011: 8-9.

[2] MANJULA W, VIVIEN P, NAOMAL D, et al. Selecting a text similarity measure for a content-based recommender system [J]. The Electronic Library, 2019, 37(3): 506-527.

- [3] SUN X, XU X L, et al. CROA: A Content-Based Recommendation Optimization Algorithm for Personalized Knowledge Services [C] // 21st International Conference on High Performance Computing and Communications. 2019:804-810.
- [4] YANIR S, INGRID Z, FABIAN B, et al. Collaborative Inference of Sentiments from Texts [C] // The 18th International Conference. 2010:195-206.
- [5] AMIT K J, LIU H M, Ingo F, et al. Information Foraging for Enhancing Implicit Feedback in Content-based Image Recommendation [C] // the 11th Forum for Information Retrieval Evaluation. 2019:65-69.
- [6] DAVID G, DAVID A N, BRIAN M O, et al. Using collaborative filtering to weave an information tapestry [C] // Communications of the ACM. 1992:61-70.
- [7] PAUL R, NEOPHYTOS L, MITESH S, et al. GroupLens: an open architecture for collaborative filtering of netnews [C] // ACM 1994 Conference on Computer Supported Cooperative Work. 1994:175-186.
- [8] BADRUL M, GEORGE K, JOSEPH A, et al. Item-based collaborative filtering recommendation algorithms [C] // The 10th International Conference on World Wide Web. 2011:285-295.
- [9] GREG L, BRENT S, JEREMY Y, et al. Amazon. com Recommendations: Item-to-Item Collaborative Filtering [J]. IEEE Internet Computing, 2003, 7(1):76-80.
- [10] YEHUDA K A. Factorization meets then eighborhood: a multifaceted collaborative filtering model [C] // The 14th International Conference on Knowledge Discovery and Data Mining. 2008:426-434.
- [11] DANIEL D L, SEBASTIAN S. Learning the parts of objects by non-negative matrix factorization [C] // Nature. 1999:788-791.
- [12] PAN R, ZHOU Y H, CAO B, et al. One-class collaborative filtering [C] // The 2008 8th IEEE International Conference on Data Mining. 2008:1-25.
- [13] RUSLAN S, ANDRIY M, et al. Probabilistic Matrix Factorization [C] // Advances in Neural Information Processing Systems 20. 2007:1-8.
- [14] MA H, IRWIN K, MICHAEL R L, et al. Learning to Recommend with Social Trust Ensemble [C] // International Conference on Research and Development in Information Retrieval. 2009:203-210.
- [15] WU X Y, CHEN Q M, LIU H, et al. Collaborative Filtering Recommendation Algorithm Based on Representation Learning of Knowledge Graph [J]. Computer Engineering, 2018, 44(2):226-232, 263.
- [16] DAVID M B, ANDREW Y, et al. Latent Dirichlet Allocation [C] // Journal of Machine Learning Research. 2003:993-1022.
- [17] CHEN C C, ZHENG X L, WANG Y, et al. Capturing Semantic Correlation for Item Recommendation in Tagging Systems [C] // The 13th AAAI Conference on Artificial Intelligence. 2016:108-114.
- [18] WANG H, WANG N Y. Collaborative Deep Learning for Recommender Systems [C] // The 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2015:1235-1244.
- [19] WANG C, DAVID M B. Collaborative topic modeling for recommending scientific articles [C] // IEEE Transactions on Pattern Analysis and Machine Intelligence. 2011:448-456.
- [20] SANJAY P, LIU Y. Collaborative Topic Regression with Social Matrix Factorization for Recommendation Systems [C] // The 29th International Conference on Machine Learning. 2012:1-8.
- [21] AYSUN B, BIRGUL K. HybRecSys: Content-based contextual hybrid venue recommender system [J]. Journal of Information Science, 2019, 45(2):212-226.
- [22] VIPUL V, KULKARNI G R. Hybrid Recommender Systems: Survey and Experiments [C] // The 2012 Digital Information and Communication Technology and its Applications (DICTAP). 2012:469-473.
- [23] CHEN X, XU H T, ZHANG Y F, et al. Sequential recommendation with user memory networks [C] // The 11th ACM International Conference on Web Search and Data Mining. 2018:108-116.
- [24] NIU W, JAMES C, LU H K, et al. Neural Personalized Ranking for Image Recommendation [C] // the 11th ACM International Conference on Web Search and Data Mining. 2018:423-431.
- [25] BALAZS H, ALEXANDROS K, LINAS B, et al. Session-based recommendations with recurrent neural networks [C] // International Conference on Learning Representations. 2016:10-15.
- [26] YU F, LIU Q, WU S, et al. A dynamic recurrent model for next basket recommendation [C] // The 39th International ACM SIGIR conference on Research and Development in Information Retrieval. 2016:729-732.
- [27] ZHOU M Z, DING Z Y, TANG J L, et al. Micro Behaviors: A New Perspective in Ecommerce Recommender Systems [C] // The 11th ACM International Conference on Web Search and Data Mining. 2018:727-735.
- [28] DUC T L, HADY W L, FANG Y. Correlation-Sensitive Next-Basket Recommendation [C] // The 28th International Joint Conference on Artificial Intelligence. 2019:2808-2814.
- [29] WANG S, SUN L, FAN W, et al. An automated CNN recommendation system for image classification tasks [C] // 2017 IEEE International Conference on Multimedia and Expo. 2017:283-288.
- [30] ZHENG L, VAHID N, PHILIP S Y, et al. Joint deep modeling of users and items using reviews for recommendation [C] // The 11th ACM International Conference on Web Search and Data Mining. 2017:425-434.
- [31] MA R F, ZHANG Q, WANG J W, et al. Mention Recommendation for Multimodal Microblog with Cross-attention Memory Network [C] // The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. 2018:195-204.
- [32] TANG J X, WANG K. Personalized Top-N Sequential Recommendation via Convolutional Sequence Embedding [C] // 11th



- ACM International Conference on Web Search and Data Mining, 2018;565-573.
- [33] LI C L, NIU X C, LUO X Y, et al. A Review-Driven Neural Model for Sequential Recommendation [C]// The 28th International Joint Conference on Artificial Intelligence Main Track. 2019;2866-2872.
- [34] WANG J, YU L T, ZHANG W N, et al. IRGAH: A Minimax Game for Unifying Generative Information Retrieval Models [C]// The 40th International ACM SIGIR Conference on Research and Development in Information. 2017;515-524.
- [35] WU Q, LIU Y, MIAO C Y, et al. PD-GAN: Adversarial Learning for Personalized Diversity-Promoting Recommendation [C]// The 28th International Joint Conference on Artificial Intelligence Main track, 2019;3870-3876.
- [36] WANG L, ZHANG W, HE X F, et al. Supervised Reinforcement Learning with Recurrent Neural Network for Dynamic Treatment Recommendation [C]// 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019; 2447-2456.
- [37] ZHAO X Y, XIA L, YIN D W, et al. Model-Based Reinforcement Learning for Whole-Chain Recommendations [C]// The 13th ACM International Conference on Web Search and Data Mining. 2019;4-8.
- [38] ZHAO X Y, ZHANG L, DING Z Y, et al. Recommendations with Negative Feedback via Pairwise Deep Reinforcement Learning [C]// The 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018;1040-1048.
- [39] ZOU L X, XIA L, DING Z Y, et al. Reinforcement Learning to Optimize Long-term User Engagement in Recommender Systems [C]// The 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019;2810-2818.
- [40] SHI C, LIU J, ZHUANG F Z, et al. Integrating heterogeneous information via flexible regularization framework for recommendation [M]. Knowledge and Information Systems, 2016; 835-859.
- [41] YU X, REN X, SUN Y Z, et al. Personalized entity recommendation: A heterogeneous information network approach [C]// The 7th ACM International Conference on Web Search and Data Mining. 2014;283-292.
- [42] WANG R R, MA X, JIANG C, et al. Heterogeneous information network-based music recommendation system in mobile networks[J]. Computer Communications, 2020, 150(1):429-437.
- [43] WU S, LI H F, LIU L, et al. A Venture Capital Recommendation Algorithm based on Heterogeneous Information Network [J]. International Journal of Computers Communications & Control, 2020, 15(1):1-8.
- [44] HU B B, SHI C. Leveraging Meta-pathbased Context for Top-N Recommendation with ANeural Co-Attention Model [C]// The 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018;1531-1540.
- [45] WANG Z K, LIU H Z, DU Y P, et al. Unified Embedding Model over Heterogeneous Information Network for Personalized Recommendation [C]// The 28th International Joint Conference on Artificial Intelligence. 2019;3813-3819.
- [46] YANG L Q, EUGENE B, JOSHUA G, et al. OpenRec: A Modular Framework for Extensible and Adaptable Recommendation Algorithms [C]// The 11th ACM Conference on Web Search and Data Mining. 2018;664-672.
- [47] YI T, ANH T L. Multi-Pointer Co-Attention Networks for Recommendation [C]// The 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018; 2309-2318.
- [48] ZHANG Y, YIN H Z, HUANG Z, et al. Discrete Deep Learning for Fast Content-Aware Recommendation [C]// The 11th ACM International Conference on Web Search and Data Mining. 2018; 717-726.



**LIU Jun-liang**, born in 1996, postgraduate. His main research interests include recommended algorithm and reinforcement learning.



**LI Xiao-guang**, born in 1973, Ph.D, professor, is a member of China Computer Federation. His main research interests include machine learning and data mining.